

# Análisis Predictivo de Ingresos (Dataset Adult) mediante Algoritmos de Machine Learning

Hans Andre Perez Sequeiros      Alvaro Vladimir Porras Durand  
Anderson Huamani Alarcon

3 de agosto de 2026

## Resumen

Este estudio compara cinco algoritmos de clasificación supervisada para predecir si el ingreso anual de una persona es menor o igual a \$50 000 o superior a dicho umbral, utilizando el conjunto de datos *Adult* del repositorio UCI. Después de eliminar 24 registros duplicados, se trabajó con 32 537 observaciones y 14 variables predictoras originales. Se evaluaron tres escenarios: datos originales, balanceo mediante SMOTE y balanceo mediante SMOTE con optimización de hiperparámetros usando GridSearchCV. Todos los modelos emplearon la misma división estratificada de entrenamiento y prueba, así como validación cruzada estratificada de cinco particiones. Random Forest con SMOTE obtuvo el mejor resultado general, con Accuracy de 0.8519, Precision de 0.6817, Recall de 0.7226, F1-Score de 0.7015 y MCC de 0.6036 para la clase >50K. La importancia por permutación identificó al estado civil, la ganancia de capital, la edad y la ocupación como las variables con mayor contribución predictiva. Los resultados muestran que el balanceo mejora la detección de la clase minoritaria, aunque produce una disminución moderada de la exactitud y la precisión.

**Palabras clave:** clasificación, Adult Census Income, Random Forest, SMOTE, GridSearchCV, MCC.

## 1. Introducción

En los últimos años, el crecimiento acelerado de los datos generados por organizaciones, instituciones y personas ha impulsado el desarrollo de nuevas técnicas para su análisis e interpretación. En este contexto, la minería de datos y el aprendizaje automático (Machine Learning) se han consolidado como herramientas fundamentales para descubrir patrones ocultos, generar conocimiento útil y apoyar la toma de decisiones en diversos ámbitos, como la salud, la educación, las finanzas y el sector empresarial. Estas técnicas permiten construir modelos predictivos capaces de analizar grandes volúmenes de información con mayor rapidez y precisión que los métodos tradicionales.

Uno de los problemas más estudiados dentro de la minería de datos es la predicción del nivel de ingresos de una persona a partir de sus características demográficas, educativas y laborales. Esta información resulta de gran interés para organismos gubernamentales, instituciones financieras y empresas, ya que facilita la elaboración de políticas públicas, el análisis socioeconómico, la segmentación de clientes y la evaluación del riesgo crediticio. Sin embargo, la elevada cantidad de registros y la diversidad de variables dificultan la identificación manual de patrones, haciendo necesario el empleo de algoritmos de Machine Learning que automatizen el proceso de clasificación.

Para el desarrollo de esta investigación se empleó el conjunto de datos *Adult* (Census Income), disponible en el repositorio oficial de UCI Machine Learning Repository. Este dataset contiene información de 32 561 registros y 15 atributos relacionados con variables como edad, nivel educativo, ocupación, estado civil, horas trabajadas por semana, país de origen e ingresos anuales. La variable objetivo (*Income*) permite clasificar a cada individuo en dos categorías: ingresos menores o iguales a \$50 000 e ingresos superiores a \$50 000 por año, convirtiéndose en uno de los conjuntos de datos más utilizados para evaluar algoritmos de clasificación supervisada.

Diversos estudios han demostrado la efectividad de los algoritmos de Machine Learning para resolver este problema. Chakrabarty and Biswas (2020) señalaron que un adecuado proceso de preprocesamiento mejora significativamente el desempeño de los modelos de clasificación. De manera similar, Thapa

(2023) compararon diferentes algoritmos utilizando el dataset Adult y concluyeron que Random Forest obtiene un rendimiento superior frente a otros modelos tradicionales. Asimismo, Anitha et al. (2024) evidenciaron que los algoritmos basados en árboles presentan una mayor capacidad de generalización cuando se combinan con técnicas adecuadas de preparación de datos. Por otra parte, Chu (2025) identificaron que variables como la edad, el nivel educativo y las horas trabajadas por semana constituyen factores determinantes para la predicción del nivel de ingresos.

Considerando estos antecedentes, el presente estudio tiene como objetivo aplicar y comparar diferentes algoritmos de Machine Learning para predecir el nivel de ingresos utilizando el dataset Adult. Para alcanzar este propósito se realizó un análisis exploratorio de los datos, seguido del proceso de preprocesamiento, transformación de variables, división del conjunto de datos para entrenamiento y prueba, entrenamiento de cinco algoritmos de clasificación y evaluación de su desempeño mediante métricas como Accuracy, Precision, Recall, F1-Score, Matthews Correlation Coefficient (MCC) y Validación Cruzada.

El presente artículo se encuentra organizado de la siguiente manera. En la Sección 2 se describe la metodología empleada, incluyendo la descripción del conjunto de datos, el análisis exploratorio, el preprocesamiento, los algoritmos de Machine Learning utilizados y las métricas de evaluación consideradas. Posteriormente, en la Sección 3 se presentan los resultados experimentales obtenidos, mientras que en la Sección 4 se discuten los principales hallazgos y se comparan con investigaciones relacionadas. Finalmente, en la Sección 5 se exponen las conclusiones y las posibles líneas de trabajo futuro derivadas de la investigación.

## 2. Método

En esta sección se describe el procedimiento seguido para desarrollar el estudio. Se presenta el conjunto de datos, el análisis exploratorio, el preprocesamiento, los algoritmos evaluados, el diseño de los tres experimentos y las métricas utilizadas para seleccionar el modelo final.

### 2.1. Dataset

Para desarrollar este proyecto se utilizó el dataset *Adult*, también conocido como *Census Income*. Este conjunto de datos fue obtenido del repositorio oficial UCI Machine Learning Repository, disponible en: <https://archive.ics.uci.edu/dataset/2/adult>

El dataset fue construido a partir de información del Censo de los Estados Unidos y es ampliamente utilizado como conjunto de referencia para problemas de clasificación binaria en Machine Learning.

En este trabajo se utilizó una versión del dataset conformada inicialmente por 32 561 registros y 15 columnas. De estas columnas, 14 corresponden a variables predictoras y una a la variable objetivo. Durante la limpieza se detectaron y eliminaron 24 registros duplicados, por lo que el modelado se realizó con 32 537 observaciones. Cada registro representa a una persona e incluye información demográfica, educativa, laboral y económica.

La variable objetivo del estudio es **Income**, la cual indica si una persona obtiene ingresos menores o iguales a \$50 000 al año o si supera ese monto. Esta variable presenta dos clases:

- $\leq 50K$ : ingresos menores o iguales a \$50 000 al año.
- $> 50K$ : ingresos mayores a \$50 000 al año.

Debido a que solamente existen dos posibles resultados, este proyecto corresponde a un problema de clasificación binaria.

Durante la revisión inicial se identificó que el conjunto de datos no estaba balanceado. La clase  $\leq 50K$  contiene 24 720 registros, lo que representa el 75.92 % del total, mientras que la clase  $> 50K$  contiene 7 841 registros, equivalente al 24.08 %. Esta diferencia será considerada durante la evaluación de los modelos mediante métricas como F1-Score y MCC.

Los atributos predictivos utilizados en el dataset se presentan en la Tabla 2. Estos atributos permiten describir aspectos personales, laborales y económicos de cada individuo, los cuales serán utilizados por los modelos de Machine Learning para predecir la clase de ingresos.

Tabla 1: Características generales del dataset Adult utilizado

| Característica                           | Valor                           |
|------------------------------------------|---------------------------------|
| Origen                                   | UCI Machine Learning Repository |
| Número inicial de registros              | 32 561                          |
| Registros después de eliminar duplicados | 32 537                          |
| Número de columnas                       | 15                              |
| Características predictoras              | 14                              |
| Variable objetivo                        | Income                          |
| Tipo de problema                         | Clasificación binaria           |
| Número de clases                         | 2                               |
| Clase mayoritaria                        | $\leq 50K$ (75.92 %)            |
| Clase minoritaria                        | $> 50K$ (24.08 %)               |

Tabla 2: Atributos del dataset Adult

| Atributo       | Descripción                  |
|----------------|------------------------------|
| Age            | Edad de la persona.          |
| Workclass      | Tipo de trabajo.             |
| fnlwt          | Peso muestral del censo.     |
| Education      | Nivel educativo.             |
| Education_num  | Años de educación.           |
| Marital_status | Estado civil.                |
| Occupation     | Ocupación.                   |
| Relationship   | Relación familiar.           |
| Race           | Raza.                        |
| Sex            | Sexo.                        |
| Capital_gain   | Ganancia de capital.         |
| Capital_loss   | Pérdida de capital.          |
| Hours_per_week | Horas trabajadas por semana. |
| Native_country | País de origen.              |

La información contenida en este conjunto de datos resulta adecuada para el objetivo del proyecto, ya que reúne variables personales, laborales y económicas que permiten entrenar modelos de clasificación y comparar su desempeño en la predicción del nivel de ingresos.

## 2.2. Análisis Exploratorio de Datos (EDA)

Antes de entrenar los modelos de Machine Learning se realizó un Análisis Exploratorio de Datos (Exploratory Data Analysis, EDA) con el propósito de comprender las características del conjunto de datos y detectar posibles problemas que pudieran afectar el desempeño de los modelos.

Durante esta etapa se analizaron tanto las variables numéricas como las categóricas, evaluando su distribución, la presencia de valores faltantes, registros duplicados, valores atípicos y la relación existente entre las variables predictoras y la variable objetivo **Income**. Asimismo, se calcularon estadísticas descriptivas y se construyeron diferentes visualizaciones que permitieron comprender mejor el comportamiento de la información.

El análisis exploratorio permitió identificar un desbalance entre las clases del conjunto de datos, la existencia de valores representados mediante el símbolo “?”, la presencia de registros duplicados y diferencias importantes en la escala de algunas variables numéricas. Estos hallazgos sirvieron como base para definir las estrategias de limpieza, transformación y estandarización aplicadas posteriormente durante el preprocesamiento de los datos.

### 2.2.1. Estadísticas descriptivas

Con el objetivo de comprender el comportamiento de las variables numéricas del conjunto de datos, se calcularon las principales estadísticas descriptivas, incluyendo la media, desviación estándar, valores mínimos, máximos y cuartiles.

Tabla 3: Resumen estadístico de las variables numéricas del dataset Adult

| Variable       | Media     | Desv. Est. | Mín.  | Máx.    |
|----------------|-----------|------------|-------|---------|
| Age            | 38.58     | 13.64      | 17    | 90      |
| fnlwgt         | 189778.37 | 105549.98  | 12285 | 1484705 |
| Education_num  | 10.08     | 2.57       | 1     | 16      |
| Capital_gain   | 1077.65   | 7385.29    | 0     | 99999   |
| Capital_loss   | 87.30     | 402.96     | 0     | 4356    |
| Hours_per_week | 40.44     | 12.35      | 1     | 99      |

La Tabla 3 se obtuvo al resumir las variables numéricas del dataset. Su función fue mostrar sus escalas y rangos antes del entrenamiento. Se observa que **fnlwgt**, **Capital\_gain** y **Capital\_loss** manejan valores mucho mayores que **Age** o **Education\_num**. Esta diferencia podía afectar a modelos sensibles a la distancia, por lo que la tabla sirvió para justificar la estandarización de las variables numéricas.

### 2.2.2. Distribución de la variable objetivo

Se analizó la distribución de la variable objetivo **Income** para conocer la proporción de personas con ingresos menores o iguales a \$50 000 y aquellas con ingresos superiores a dicho monto.

La Figura 1 muestra que la clase  $\leq 50K$  es mucho más frecuente que la clase  $> 50K$ . Esto significa que un modelo podría obtener una Accuracy alta al favorecer a la clase mayoritaria. La figura sirvió para decidir que el análisis no debía depender solo de Accuracy, sino también de Recall, F1-Score y MCC para la clase minoritaria.

La Tabla 4 presenta los valores exactos del desbalance: aproximadamente tres de cada cuatro personas pertenecen a  $\leq 50K$ . Esta información se utilizó para aplicar una división estratificada y, posteriormente, evaluar SMOTE como alternativa para mejorar la detección de  $> 50K$ .




Figura 1: Distribución de la variable objetivo Income.

Tabla 4: Distribución de la variable objetivo Income

| Clase | Cantidad | Porcentaje |
|-------|----------|------------|
| <=50K | 24 720   | 75.92 %    |
| >50K  | 7 841    | 24.08 %    |

### 2.2.3. Distribución de variables numéricas

Se analizaron las variables numéricas `Age`, `fnlwgt`, `Education_num`, `Capital_gain`, `Capital_loss` y `Hours_per_week`. Este análisis permitió observar la concentración de los datos y posibles valores extremos.

Tabla 5: Resumen del comportamiento de variables numéricas

| Variable                    | Observación principal                                                      |
|-----------------------------|----------------------------------------------------------------------------|
| <code>Age</code>            | La mayoría de personas se concentra entre 20 y 50 años.                    |
| <code>fnlwgt</code>         | Presenta alta dispersión y valores elevados en algunos registros.          |
| <code>Education_num</code>  | La mayor parte de registros se ubica entre niveles educativos intermedios. |
| <code>Capital_gain</code>   | La mayoría de valores son 0, con algunos valores extremos.                 |
| <code>Capital_loss</code>   | Presenta comportamiento similar a <code>Capital_gain</code> .              |
| <code>Hours_per_week</code> | La mayoría trabaja alrededor de 40 horas semanales.                        |

La Tabla 5 resume cómo se distribuyen las variables numéricas. `Capital_gain` y `Capital_loss` contienen muchos ceros y pocos valores altos, mientras que `Age` y `Hours_per_week` se concentran alrededor de valores habituales. Este análisis ayudó a conservar los datos reales y a tratarlos mediante escalado, en lugar de eliminar automáticamente los valores grandes.

### 2.2.4. Valores atípicos

Para identificar valores atípicos se utilizó el método del rango intercuartílico (IQR). Este análisis permitió conocer qué variables presentan observaciones alejadas del comportamiento general de los datos.




Figura 2: Distribución de las horas trabajadas por semana según el nivel de ingresos.

La Figura 2 evidencia la presencia de numerosos valores atípicos en la variable `Hours_per_week`. Sin embargo, estos registros representan casos reales y no errores de captura, por lo que fueron conservados durante el preprocesamiento.

Tabla 6: Cantidad de valores atípicos identificados mediante IQR

| Variable       | Cantidad de outliers | Porcentaje |
|----------------|----------------------|------------|
| Age            | 143                  | 0.44 %     |
| fnlwgt         | 992                  | 3.05 %     |
| Education_num  | 1 198                | 3.68 %     |
| Capital_gain   | 2 712                | 8.33 %     |
| Capital_loss   | 1 519                | 4.67 %     |
| Hours_per_week | 9 008                | 27.66 %    |

La Tabla 6 se obtuvo mediante el método IQR y muestra qué valores se alejan del comportamiento central. `Hours_per_week` presentó la mayor cantidad de casos señalados. Sin embargo, el método IQR solo indica que un valor es poco común, no que sea incorrecto. Por esta razón se conservaron los registros y se evitó perder casos laborales reales.

### 2.2.5. Análisis de variables categóricas

Además de las variables numéricas, se analizaron las principales variables categóricas presentes en el conjunto de datos, tales como `Workclass`, `Education`, `Marital_status`, `Occupation`, `Relationship`, `Race`, `Sex` y `Native_country`. Este análisis permitió conocer la distribución de las categorías y detectar posibles desbalances entre ellas.

La Tabla 7 muestra las categorías predominantes en cada variable. Esta revisión permitió comprobar que los datos categóricos contenían información útil, pero no podían ingresar directamente a los algoritmos. Por ello se aplicó One-Hot Encoding, convirtiendo cada categoría en valores numéricos sin asignarle un orden artificial.

Tabla 7: Principales observaciones de las variables categóricas

| Variable       | Observación                                                           |
|----------------|-----------------------------------------------------------------------|
| Workclass      | Predomina la categoría Private.                                       |
| Education      | High School y Some-college concentran la mayor cantidad de registros. |
| Marital_status | Married-civ-spouse representa la categoría con mayor frecuencia.      |
| Occupation     | Existen diferencias importantes entre las ocupaciones registradas.    |
| Relationship   | Husband y Not-in-family presentan mayor frecuencia.                   |
| Race           | La mayoría de registros pertenece a la categoría White.               |
| Sex            | Predomina el sexo masculino.                                          |
| Native_country | La mayor parte de personas proviene de Estados Unidos.                |

### 2.2.6. Análisis de correlación

Con el propósito de identificar la relación existente entre las variables numéricas, se calculó la matriz de correlación utilizando el coeficiente de Pearson. Este análisis permitió conocer el grado de asociación lineal entre los diferentes atributos del conjunto de datos.




Figura 3: Matriz de correlación entre las variables numéricas del dataset Adult.

La Figura 3 muestra que las correlaciones entre las variables numéricas son relativamente bajas, por lo que no se identificaron problemas importantes de multicolinealidad.

La Figura 3 y la Tabla 8 muestran que no existen relaciones lineales extremadamente altas entre las variables numéricas. Esto indica que ninguna variable repite casi por completo la información de otra. El análisis sirvió para conservar todas las variables numéricas y permitir que los modelos aprendieran relaciones tanto lineales como no lineales.

Tabla 8: Resumen del análisis de correlación

| Observación             | Descripción                                                                                      |
|-------------------------|--------------------------------------------------------------------------------------------------|
| Correlaciones altas     | No se identificaron correlaciones extremadamente altas entre las variables numéricas.            |
| Correlaciones moderadas | Algunas variables presentan relaciones moderadas, principalmente asociadas con educación y edad. |
| Multicolinealidad       | No se observaron problemas significativos de multicolinealidad.                                  |

### 2.2.7. Importancia de las variables

Durante el análisis exploratorio no se asignó una importancia predictiva definitiva a las variables, ya que dicha estimación depende del modelo entrenado y debe realizarse después de seleccionar la configuración final. Por este motivo, la importancia se calculó posteriormente mediante *Permutation Importance* sobre el conjunto de prueba, utilizando el MCC como función de evaluación. Los resultados cuantitativos se presentan en la Sección de Resultados.

## 2.3. Preprocesamiento de datos

Después de realizar el análisis exploratorio de los datos, se ejecutó la etapa de preprocesamiento con el propósito de preparar el conjunto de datos para el entrenamiento de los modelos de Machine Learning. Durante esta fase se realizaron actividades de limpieza, transformación, codificación, división del conjunto de datos y estandarización de las variables numéricas.

### 2.3.1. Limpieza de datos

En primer lugar, se verificó la calidad del conjunto de datos mediante la identificación de valores faltantes, registros duplicados y valores representados mediante el símbolo “?”. Se eliminaron 24 registros duplicados. Los símbolos “?” se transformaron en valores nulos, pero su imputación no se realizó sobre el dataset completo: las variables numéricas se imputaron con la mediana y las categóricas con la categoría más frecuente dentro del pipeline, utilizando únicamente los datos disponibles en cada entrenamiento. Esta decisión evitó la fuga de información hacia el conjunto de prueba.

Tabla 9: Resumen del proceso de limpieza de datos

| Proceso               | Resultado obtenido                           |
|-----------------------|----------------------------------------------|
| Valores “?”           | Convertidos a valores nulos.                 |
| Imputación numérica   | Mediana calculada dentro del pipeline.       |
| Imputación categórica | Categoría más frecuente dentro del pipeline. |
| Registros duplicados  | 24 registros eliminados.                     |
| Resultado final       | 32 537 registros para el modelado.           |

La Tabla 9 resume qué se corrigió y dónde se realizó cada tratamiento. La imputación se incluyó dentro del pipeline para que las medianas y categorías más frecuentes se calcularan solo con datos de entrenamiento. Esto sirvió para evitar fuga de información y obtener una evaluación más confiable.

### 2.3.2. Transformación y codificación de variables

Debido a que los algoritmos de Machine Learning requieren variables numéricas como entrada, las variables categóricas se transformaron mediante One-Hot Encoding con eliminación de la primera categoría y manejo de categorías desconocidas. La transformación se ajustó dentro del pipeline para evitar que la información del conjunto de prueba interviniera en el entrenamiento.

La Tabla 10 explica cómo se convirtieron los datos categóricos en información utilizable por los modelos. El resultado fue una representación numérica consistente, capaz de procesar categorías nuevas sin



Tabla 10: Transformaciones aplicadas a las variables

| Transformación          | Descripción                                                 |
|-------------------------|-------------------------------------------------------------|
| One-Hot Encoding        | Conversión de variables categóricas a indicadores binarios. |
| Primera categoría       | Eliminada para reducir redundancia.                         |
| Categorías desconocidas | Ignoradas durante la transformación de prueba.              |
| Variable objetivo       | $\leq 50K=0$ y $>50K=1$ .                                   |

detener la predicción.

### 2.3.3. Separación de variables predictoras y variable objetivo

Posteriormente, el conjunto de datos fue dividido en variables predictoras ( $X$ ) y variable objetivo ( $y$ ). Las variables predictoras corresponden a todas las características demográficas y laborales del dataset, mientras que la variable objetivo corresponde al atributo **Income**.

Tabla 11: Separación del conjunto de datos

| Elemento                                    | Cantidad |
|---------------------------------------------|----------|
| Variables predictoras originales ( $X$ )    | 14       |
| Características después de One-Hot Encoding | 97       |
| Variable objetivo ( $y$ )                   | 1        |

La Tabla 11 diferencia las 14 variables originales de las 97 características obtenidas después de One-Hot Encoding. Esta aclaración permite entender que no se agregaron nuevas fuentes de información: las 97 columnas provienen de transformar las categorías de las variables originales.

### 2.3.4. División del conjunto de datos

Con el fin de evaluar correctamente el desempeño de los modelos, el conjunto de datos fue dividido utilizando una proporción del 80 % para entrenamiento y 20 % para prueba. Además, se utilizó una división estratificada para conservar la misma proporción de clases en ambos conjuntos.

Tabla 12: División del conjunto de datos

| Conjunto      | Registros | Porcentaje |
|---------------|-----------|------------|
| Entrenamiento | 26 029    | 80 %       |
| Prueba        | 6 508     | 20 %       |

La Tabla 12 muestra de dónde salieron los datos utilizados en los experimentos. La estratificación mantuvo una proporción similar de ambas clases en entrenamiento y prueba. Además, conservar el mismo conjunto de prueba permitió comparar los 15 resultados bajo las mismas condiciones.

### 2.3.5. Estandarización de variables

Finalmente, las seis variables numéricas fueron estandarizadas mediante StandardScaler. El escalador se ajustó únicamente con los datos de entrenamiento dentro del pipeline y la misma transformación se aplicó al conjunto de prueba, evitando fuga de información. Los modelos basados en árboles no requieren necesariamente estandarización, pero se mantuvo el mismo preprocesamiento para asegurar condiciones comparables entre los cinco algoritmos.

La Tabla 13 indica qué variables fueron estandarizadas. Este paso fue importante para Regresión Logística, KNN y SVM, porque comparan valores y distancias. También permitió mantener un preprocesamiento común para los cinco algoritmos.

Tabla 13: Variables estandarizadas

| Variable       | Estado        |
|----------------|---------------|
| Age            | Estandarizada |
| fnlwgt         | Estandarizada |
| Education_num  | Estandarizada |
| Capital_gain   | Estandarizada |
| Capital_loss   | Estandarizada |
| Hours_per_week | Estandarizada |

## 2.4. Algoritmos de Machine Learning

Para el desarrollo del proyecto se seleccionaron cinco algoritmos de clasificación supervisada. Estos modelos fueron elegidos porque permiten comparar diferentes formas de aprendizaje: modelos lineales, modelos basados en reglas, modelos por conjunto de árboles, modelos basados en distancia y modelos de separación entre clases.

Tabla 14: Algoritmos seleccionados para el experimento

| Modelo              | Motivo de selección                                                  |
|---------------------|----------------------------------------------------------------------|
| Regresión Logística | Se utiliza como modelo base para problemas de clasificación binaria. |
| Árbol de Decisión   | Permite clasificar mediante reglas fáciles de interpretar.           |
| Random Forest       | Combina varios árboles de decisión y ayuda a reducir el sobreajuste. |
| KNN                 | Clasifica según la cercanía entre registros similares.               |
| SVM                 | Busca una separación adecuada entre las clases del problema.         |

### 2.4.1. Regresión Logística

La Regresión Logística es uno de los algoritmos supervisados más utilizados para problemas de clasificación binaria. Fue propuesta por David R. Cox en 1958 mediante el trabajo titulado *The Regression Analysis of Binary Sequences* (Cox, 1958). El algoritmo estima la probabilidad de que una observación pertenezca a una determinada clase utilizando la función logística o función sigmoide.

La probabilidad de pertenencia a la clase positiva se calcula mediante la siguiente expresión matemática:

$$P(y = 1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta^T x)}}$$

donde  $\beta_0$  representa el intercepto del modelo,  $\beta$  corresponde al vector de coeficientes asociados a las variables predictoras y  $x$  representa las características de entrada del modelo.

Para el desarrollo del presente trabajo se emplearon los hiperparámetros mostrados en la Tabla 15.

Tabla 15: Hiperparámetros utilizados en Regresión Logística

| Parámetro    | Valor |
|--------------|-------|
| Solver       | lbfgs |
| Max_iter     | 2000  |
| Random_state | 42    |

### 2.4.2. Árbol de Decisión

El algoritmo Árbol de Decisión fue desarrollado por Breiman, Friedman, Olshen y Stone en la obra *Classification and Regression Trees (CART)* publicada en 1984 (Breiman et al., 1984). Este modelo organiza los datos mediante una estructura jerárquica de decisiones, permitiendo clasificar nuevas observaciones a partir de reglas simples.

La impureza de cada nodo se calcula utilizando el índice de Gini:

$$Gini = 1 - \sum_{i=1}^c p_i^2$$

donde  $p_i$  representa la probabilidad de pertenecer a la clase  $i$ .

Los hiperparámetros utilizados durante el entrenamiento se presentan en la Tabla 16.

Tabla 16: Hiperparámetros utilizados en Árbol de Decisión

| Parámetro    | Valor |
|--------------|-------|
| Criterion    | gini  |
| Max_depth    | None  |
| Random_state | 42    |

### 2.4.3. Random Forest

Random Forest fue propuesto por Leo Breiman en 2001 mediante el artículo *Random Forests* (Breiman, 2001). Este algoritmo construye múltiples árboles de decisión independientes y combina sus predicciones mediante un proceso de votación mayoritaria, reduciendo el sobreajuste y mejorando la capacidad de generalización.

La predicción final del modelo se expresa como:

$$\hat{y} = mode\{T_1(x), T_2(x), \dots, T_n(x)\}$$

donde  $T_i(x)$  representa la predicción realizada por cada árbol del bosque.

Los hiperparámetros utilizados se muestran en la Tabla 17.

Tabla 17: Hiperparámetros utilizados en Random Forest

| Parámetro    | Valor |
|--------------|-------|
| n_estimators | 100   |
| Criterion    | gini  |
| Random_state | 42    |

### 2.4.4. K-Vecinos Más Cercanos

El algoritmo K-Nearest Neighbors (KNN) fue introducido por Cover y Hart en 1967 mediante el artículo *Nearest Neighbor Pattern Classification* (Cover and Hart, 1967). Este método clasifica una nueva observación considerando la clase predominante entre sus vecinos más cercanos.

La distancia euclidiana utilizada para medir la similitud entre observaciones se define como:

$$d(p, q) = \sqrt{\sum_{i=1}^n (q_i - p_i)^2}$$

donde  $p$  y  $q$  representan dos observaciones del conjunto de datos.

Los hiperparámetros empleados se muestran en la Tabla 18.

Tabla 18: Hiperparámetros utilizados en KNN

| Parámetro   | Valor     |
|-------------|-----------|
| n_neighbors | 5         |
| Metric      | euclidean |
| Weights     | uniform   |

#### 2.4.5. Máquina de Vectores de Soporte

Las Máquinas de Vectores de Soporte (SVM) fueron propuestas por Cortes y Vapnik en 1995 mediante el artículo *Support-Vector Networks* (Cortes and Vapnik, 1995). El objetivo del algoritmo consiste en encontrar el hiperplano que maximiza la separación entre las diferentes clases del problema.

La función de decisión está dada por:

$$f(x) = w^T x + b$$

donde  $w$  representa el vector normal al hiperplano y  $b$  corresponde al sesgo del modelo.

Los hiperparámetros utilizados durante el entrenamiento se presentan en la Tabla 19.

Tabla 19: Hiperparámetros utilizados en SVM

| Parámetro    | Valor |
|--------------|-------|
| Kernel       | RBF   |
| C            | 1     |
| Gamma        | scale |
| Random_state | 42    |

El proceso experimental se organizó en tres escenarios. En el Experimento 1 se utilizaron los datos originales y los parámetros base de cada algoritmo. En el Experimento 2 se incorporó SMOTE dentro del pipeline para balancear únicamente los datos de entrenamiento de cada partición. En el Experimento 3 se mantuvo SMOTE y se aplicó GridSearchCV con dos configuraciones representativas por algoritmo, cinco particiones estratificadas y selección de la mejor alternativa según MCC. En total se realizaron 50 ajustes durante la búsqueda. Los tres experimentos utilizaron la misma división estratificada 80/20 y el mismo conjunto de prueba.

Tabla 20: Diseño de los experimentos

| Experimento | Configuración                                                    |
|-------------|------------------------------------------------------------------|
| E1          | Datos originales y parámetros base.                              |
| E2          | SMOTE dentro del pipeline y parámetros base.                     |
| E3          | SMOTE dentro del pipeline y GridSearchCV, con selección por MCC. |

#### 2.5. Métricas de evaluación

Para evaluar el desempeño se utilizaron Accuracy, Precision, Recall, F1-Score y MCC. Debido al desbalance del dataset, Precision, Recall y F1-Score se calcularon específicamente para la clase positiva >50K, en lugar de emplear promedios ponderados que pudieran ocultar el rendimiento sobre la clase minoritaria. Asimismo, se aplicó validación cruzada estratificada de cinco particiones sobre el conjunto de entrenamiento para estimar la estabilidad de cada modelo.

### 2.5.1. Accuracy

La Accuracy o exactitud representa la proporción de predicciones correctas realizadas por el modelo respecto al total de observaciones evaluadas. Aunque es una de las métricas más utilizadas en clasificación, puede resultar insuficiente cuando el conjunto de datos presenta desbalance entre sus clases. Su formulación fue ampliamente documentada por Powers (2011) en el análisis comparativo de métricas de evaluación para modelos de clasificación (Powers, 2011).

La Accuracy se calcula mediante la siguiente expresión:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

donde TP representa los verdaderos positivos, TN los verdaderos negativos, FP los falsos positivos y FN los falsos negativos.

### 2.5.2. Precision

La Precision mide la proporción de predicciones positivas realizadas correctamente por el modelo. Esta métrica resulta especialmente útil cuando el costo de los falsos positivos es elevado. Su definición fue recopilada por Powers (2011) (Powers, 2011).

$$Precision = \frac{TP}{TP + FP}$$

Valores altos de Precision indican que la mayoría de las observaciones clasificadas como positivas realmente pertenecen a dicha clase.

### 2.5.3. Recall

El Recall, también denominado sensibilidad, mide la capacidad del modelo para identificar correctamente los casos positivos existentes dentro del conjunto de datos. Esta métrica también fue descrita por Powers (2011) (Powers, 2011).

$$Recall = \frac{TP}{TP + FN}$$

Un valor elevado de Recall indica que el modelo logra detectar la mayor parte de los casos positivos reales.

### 2.5.4. F1-Score

El F1-Score combina las métricas Precision y Recall mediante su media armónica, proporcionando una medida equilibrada del desempeño del modelo, especialmente cuando existe desbalance entre las clases. Esta métrica también fue presentada por Powers (2011) (Powers, 2011).

$$F1 = 2 \left( \frac{Precision \times Recall}{Precision + Recall} \right)$$

Mientras más cercano sea el valor de F1-Score a uno, mejor será el equilibrio entre Precision y Recall.

### 2.5.5. Coeficiente de Correlación de Matthews (MCC)

El coeficiente de correlación de Matthews (Matthews Correlation Coefficient) fue propuesto por Matthews (1975) como una medida robusta para evaluar modelos de clasificación binaria, especialmente cuando las clases presentan desbalance (Matthews, 1975).

Su expresión matemática es:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

El MCC toma valores entre -1 y 1, donde un valor cercano a 1 indica una clasificación prácticamente perfecta.

### 2.5.6. Validación Cruzada

La Validación Cruzada (Cross Validation) es una técnica ampliamente utilizada para estimar la capacidad de generalización de un modelo de Machine Learning. En este trabajo se empleó validación cruzada de cinco particiones (5-Fold Cross Validation), dividiendo el conjunto de entrenamiento en cinco subconjuntos. En cada iteración, cuatro particiones fueron utilizadas para entrenar el modelo y una para validarlo, repitiendo el proceso hasta completar las cinco combinaciones posibles (Hastie et al., 2009).

El valor final corresponde al promedio obtenido en las cinco evaluaciones, permitiendo estimar de manera más confiable el desempeño esperado del algoritmo sobre datos no observados durante el entrenamiento.

Tabla 21: Métricas utilizadas para evaluar los modelos

| Métrica          | Objetivo                            | Rango  |
|------------------|-------------------------------------|--------|
| Accuracy         | Porcentaje de aciertos              | 0 a 1  |
| Precision        | Calidad de predicciones positivas   | 0 a 1  |
| Recall           | Detección de positivos reales       | 0 a 1  |
| F1-Score         | Equilibrio entre Precision y Recall | 0 a 1  |
| MCC              | Clasificación robusta               | -1 a 1 |
| Cross Validation | Estabilidad del modelo              | 0 a 1  |

## 3. Resultados

### 3.1. Comparación del desempeño de los modelos

La Tabla 22 reúne los resultados obtenidos en el conjunto de prueba para los cinco modelos y los tres experimentos. Estos valores salieron de comparar las predicciones con las clases reales de 6 508 registros que no se utilizaron durante el entrenamiento. Las columnas CV corresponden al promedio de cinco particiones del conjunto de entrenamiento y sirvieron para comprobar si el comportamiento del modelo era estable.

La lectura de la tabla se realizó de la siguiente manera: Accuracy indica el porcentaje total de aciertos; Precision muestra cuántas predicciones >50K fueron correctas; Recall indica cuántas personas >50K logró encontrar el modelo; F1-Score resume el equilibrio entre Precision y Recall; y MCC evalúa de forma conjunta los aciertos y errores de las dos clases. Debido al desbalance, el modelo final no se eligió únicamente por Accuracy.

En el Experimento 1, Random Forest obtuvo la mayor Accuracy (0.8603), pero solo detectó el 63.65 % de las personas con ingresos >50K. Esto muestra que una Accuracy alta no significa necesariamente que la clase minoritaria esté bien reconocida.

Al aplicar SMOTE en el Experimento 2, el Recall de Random Forest aumentó de 0.6365 a 0.7226, es decir, mejoró en 8.61 puntos porcentuales. Su F1-Score también subió de 0.6871 a 0.7015, mientras que la Accuracy disminuyó menos de un punto porcentual. Este cambio indicó que SMOTE ayudó a encontrar más casos >50K sin perder demasiado rendimiento general.

SVM alcanzó el mayor Recall (0.8635), por lo que detectó la mayor cantidad de personas >50K. Sin embargo, su Precision fue 0.5856, lo que significa que produjo más falsos positivos. Random Forest fue seleccionado porque presentó el mayor MCC (0.6036) y el mejor F1-Score (0.7015), logrando un equilibrio más útil entre detectar la clase minoritaria y evitar clasificaciones incorrectas.

La Tabla 23 salió de la mejor combinación seleccionada por GridSearchCV según MCC. Su función es dejar registrada la configuración con la que se obtuvieron los resultados y permitir que el experimento pueda repetirse. La búsqueda mejoró principalmente al Árbol de Decisión y KNN. En Random Forest,

Tabla 22: Resultados de los cinco modelos en los tres experimentos

| Exp. | Modelo               | Acc.          | Prec.         | Rec.          | F1            | MCC           | CV Acc.       | CV F1         | CV MCC        |
|------|----------------------|---------------|---------------|---------------|---------------|---------------|---------------|---------------|---------------|
| E1   | Regresión Logística  | 0.8571        | 0.7443        | 0.6199        | 0.6764        | 0.5897        | 0.8493        | 0.6538        | 0.5641        |
| E1   | Árbol de Decisión    | 0.8178        | 0.6212        | 0.6244        | 0.6228        | 0.5026        | 0.8111        | 0.6165        | 0.4916        |
| E1   | Random Forest        | 0.8603        | 0.7464        | 0.6365        | 0.6871        | 0.6011        | 0.8517        | 0.6667        | 0.5755        |
| E1   | KNN                  | 0.8360        | 0.6722        | 0.6237        | 0.6470        | 0.5411        | 0.8310        | 0.6331        | 0.5246        |
| E1   | SVM                  | 0.8589        | 0.7673        | 0.5950        | 0.6703        | 0.5900        | 0.8549        | 0.6566        | 0.5761        |
| E2   | Regresión Logística  | 0.8107        | 0.5716        | 0.8559        | 0.6854        | 0.5808        | 0.8079        | 0.6786        | 0.5703        |
| E2   | Árbol de Decisión    | 0.8122        | 0.5997        | 0.6639        | 0.6301        | 0.5059        | 0.8034        | 0.6151        | 0.4852        |
| E2   | <b>Random Forest</b> | <b>0.8519</b> | <b>0.6817</b> | <b>0.7226</b> | <b>0.7015</b> | <b>0.6036</b> | <b>0.8433</b> | <b>0.6786</b> | <b>0.5751</b> |
| E2   | KNN                  | 0.7806        | 0.5296        | 0.7997        | 0.6372        | 0.5104        | 0.7829        | 0.6390        | 0.5128        |
| E2   | SVM                  | 0.8199        | 0.5856        | <b>0.8635</b> | 0.6979        | 0.5983        | 0.8143        | <b>0.6869</b> | <b>0.5819</b> |
| E3   | Regresión Logística  | 0.8107        | 0.5716        | 0.8559        | 0.6854        | 0.5808        | 0.8079        | 0.6786        | 0.5703        |
| E3   | Árbol de Decisión    | 0.8076        | 0.5684        | 0.8374        | 0.6772        | 0.5680        | 0.8041        | 0.6696        | 0.5568        |
| E3   | Random Forest        | 0.8519        | 0.6817        | 0.7226        | 0.7015        | 0.6036        | 0.8433        | 0.6786        | 0.5751        |
| E3   | KNN                  | 0.8072        | 0.5718        | 0.7953        | 0.6652        | 0.5492        | 0.7993        | 0.6525        | 0.5311        |
| E3   | SVM                  | 0.8199        | 0.5856        | 0.8635        | 0.6979        | 0.5983        | 0.8143        | 0.6869        | 0.5819        |

Tabla 23: Configuraciones seleccionadas por GridSearchCV en el Experimento 3

| Modelo              | Mejor configuración                                                            |
|---------------------|--------------------------------------------------------------------------------|
| Regresión Logística | $C = 1,0$ , solver = lbfgs.                                                    |
| Árbol de Decisión   | criterion = gini, max_depth = 10, min_samples_split = 2, min_samples_leaf = 1. |
| Random Forest       | n_estimators = 100, max_depth = None, max_features = sqrt.                     |
| KNN                 | n_neighbors = 11, weights = distance, metric = manhattan.                      |
| SVM                 | kernel = rbf, $C = 1,0$ , gamma = scale.                                       |

SVM y Regresión Logística seleccionó configuraciones equivalentes a las ya utilizadas, por lo que no generó una mejora adicional.

Tabla 24: Aciertos y errores del modelo final en el conjunto de prueba

|                 | Predicción $\leq 50K$ | Predicción $> 50K$ |
|-----------------|-----------------------|--------------------|
| Real $\leq 50K$ | 4 411                 | 529                |
| Real $> 50K$    | 435                   | 1 133              |

La Tabla 24 se obtuvo al comparar la predicción final de Random Forest con el valor real de cada registro de prueba. El modelo acertó en 5 544 de 6 508 casos. De las 1 568 personas que realmente pertenecían a  $> 50K$ , identificó correctamente 1 133 y no detectó 435. Además, clasificó por error a 529 personas de  $\leq 50K$  como  $> 50K$ . Esta tabla sirvió para conocer qué tipo de errores estaban ocultos detrás del valor de Accuracy.

La Tabla 25 se obtuvo mediante Permutation Importance. Este método desordena una variable y mide cuánto disminuye el MCC. Si el desempeño baja bastante, significa que esa variable aportaba información importante al modelo. El estado civil produjo la mayor disminución del MCC (0.1266), seguido por la ganancia de capital (0.0852), la edad (0.0636) y la ocupación (0.0554). La tabla sirvió para explicar en qué información se apoyó principalmente el modelo, pero estos valores representan asociaciones predictivas y no relaciones de causa y efecto.

### 3.2. Comparación gráfica del desempeño de los modelos

Las figuras siguientes presentan de forma visual los mismos valores de la Tabla 22. Su propósito es facilitar la comparación entre experimentos y mostrar rápidamente dónde mejoró o disminuyó cada métrica.

La Figura 4 muestra dos resultados diferentes. A la izquierda, los modelos del Experimento 1 presentan mayor Accuracy porque trabajan con la distribución original y aciertan con frecuencia la clase mayo-

Tabla 25: Variables que más influyeron en las predicciones del modelo final

| Variable       | Disminución media del MCC | Desv. estándar |
|----------------|---------------------------|----------------|
| Marital_status | 0.126606                  | 0.007604       |
| Capital_gain   | 0.085167                  | 0.005424       |
| Age            | 0.063573                  | 0.006548       |
| Occupation     | 0.055364                  | 0.005356       |
| Relationship   | 0.032886                  | 0.004659       |
| Education_num  | 0.032692                  | 0.006690       |
| Hours_per_week | 0.025510                  | 0.007777       |
| Capital_loss   | 0.023321                  | 0.001728       |
| Workclass      | 0.010373                  | 0.003795       |
| Race           | 0.006596                  | 0.003189       |




Figura 4: Accuracy general (izquierda) y F1-Score de la clase >50K (derecha). Los valores sobre las barras corresponden al conjunto de prueba.



ritaria. A la derecha, el F1-Score mejora en varios modelos después de aplicar SMOTE, especialmente en Random Forest y SVM. Esta comparación sirvió para comprobar que el mejor modelo no debía elegirse únicamente por la cantidad total de aciertos.




Figura 5: MCC de cada modelo en los tres experimentos. Un valor mayor representa un mejor equilibrio entre ambas clases.

La Figura 5 muestra que Random Forest obtuvo el valor más alto, con 0.6036 en los Experimentos 2 y 3. SVM quedó cerca con 0.5983. También se observa que GridSearchCV mejoró el MCC del Árbol de Decisión y KNN. Este gráfico sirvió como apoyo para elegir Random Forest, porque MCC resume de forma equilibrada los cuatro resultados de la matriz de confusión.





Figura 6: Errores y aciertos del modelo final (izquierda) y variables que más reducen el MCC al ser desordenadas (derecha).

La Figura 6 resume cómo funciona el modelo final. La imagen izquierda muestra que la mayoría de los registros fue clasificada correctamente, aunque todavía existen 435 casos >50K no detectados. La imagen derecha muestra que el estado civil, la ganancia de capital, la edad y la ocupación fueron las

variables que más ayudaron a mantener el desempeño. Ambas imágenes sirvieron para responder dos preguntas: en qué casos se equivoca el modelo y qué información utiliza principalmente para decidir.

## 4. Discusión

El resultado principal fue que SMOTE permitió detectar más personas con ingresos >50K. En Random Forest, el Recall aumentó de 0.6365 a 0.7226. La pequeña disminución de Accuracy fue aceptable porque el objetivo no era acertar únicamente la clase mayoritaria, sino mejorar el reconocimiento de ambas clases.

SVM obtuvo el mayor Recall, pero su menor Precision produjo más falsos positivos. Random Forest no fue el mejor en todas las métricas por separado, pero sí obtuvo el mayor MCC y F1-Score en prueba. Por esta razón fue la opción más equilibrada para el problema analizado.

GridSearchCV sirvió para comprobar si otras configuraciones podían mejorar los modelos. El ajuste ayudó al Árbol de Decisión y KNN, pero no cambió los resultados de Random Forest, SVM y Regresión Logística. Esto indica que ajustar parámetros no siempre mejora un modelo; el resultado depende de las configuraciones evaluadas.

La importancia por permutación mostró que el modelo utilizó principalmente información familiar, económica, demográfica y laboral. El estado civil fue la variable con mayor aporte, seguida por la ganancia de capital, la edad y la ocupación. Estos resultados ayudan a entender el modelo, pero no significan que una variable cause directamente un ingreso alto.

La principal limitación fue que GridSearchCV evaluó una cuadrícula reducida de dos configuraciones por modelo para evitar problemas de tiempo y memoria. Además, el dataset representa un censo y un contexto histórico específico. Por ello, el modelo es útil para comparar técnicas, pero no debe aplicarse directamente a otras poblaciones sin una nueva evaluación.

## 5. Conclusiones

Se evaluaron cinco algoritmos bajo las mismas condiciones y en tres experimentos. Utilizar el mismo conjunto de prueba y la misma validación cruzada permitió realizar una comparación justa.

Random Forest con SMOTE fue el modelo final porque obtuvo el mayor MCC (0.6036) y el mayor F1-Score de la clase >50K (0.7015). Su Accuracy fue 0.8519 y logró detectar el 72.26 % de los casos >50K.

SMOTE fue útil porque aumentó la detección de la clase minoritaria. Aunque redujo ligeramente la Accuracy y la Precision, mejoró el equilibrio del modelo, especialmente en Random Forest, SVM y Regresión Logística.

GridSearchCV mejoró al Árbol de Decisión y KNN, pero no produjo cambios en el modelo final. Esto permitió concluir que Random Forest ya tenía una configuración adecuada dentro de las alternativas evaluadas.

Finalmente, la matriz de confusión permitió conocer los errores reales del modelo y Permutation Importance permitió identificar las variables más utilizadas. En conjunto, estas herramientas hicieron que la selección del modelo fuera más clara, justificable y fácil de interpretar.

## Referencias

- Anitha, R. et al. (2024). Adult income prediction using machine learning algorithms. *International Journal of Advanced Research in Science and Technology*.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Chapman and Hall, New York.
- Chakrabarty, N. and Biswas, S. (2020). A statistical approach to adult census income level prediction. *International Journal of Computer Applications*.

- Chu, H. (2025). Adult income prediction and key factors analysis based on machine learning algorithm. *Proceedings of ICFTB*.
- Cortes, C. and Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3):273–297.
- Cover, T. M. and Hart, P. E. (1967). Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1):21–27.
- Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society. Series B (Methodological)*, 20(2):215–232.
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning*. Springer, 2 edition.
- Matthews, B. W. (1975). Comparison of the predicted and observed secondary structure of t4 phage lysozyme. *Biochimica et Biophysica Acta*, 405(2):442–451.
- Powers, D. M. W. (2011). Evaluation: From precision, recall and f-measure to roc, informedness, markedness and correlation. *Journal of Machine Learning Technologies*, 2(1):37–63.
- Thapa, S. (2023). Predicting adult income utilizing various artificial intelligence models. *SSRN Electronic Journal*.